

THIAGO SEIKI KATO

Desenvolvedor Full Stack · Arquitetura de Soluções de IA · Supply Chain & Dados

São Paulo, SP · (11) 98103-9985 · thiagokato@gmail.com

linkedin.com/in/thiago-seiki-kato · github.com/thiagokato80 · thiagokato80.github.io/Portfolio

RESUMO

Desenvolvedor full stack e arquiteto de soluções de IA, com base anterior em consultoria estratégica e gestão de operações (EY, Webb, Rio 2016). Atuo no intervalo entre a regra de negócio e a implementação: levanto o requisito com a área, modelo os dados e escrevo o sistema — sem perda de tradução entre quem sabe a regra e quem escreve o código.

Portfólio de 12 aplicações em produção, piloto ou desenvolvimento, construídas em Python/FastAPI e TypeScript/React sobre PostgreSQL, Supabase e Google Cloud. Os domínios cobrem padronização de catálogo com embeddings e busca vetorial, simulação de eventos discretos para operações industriais, motor de cálculo tributário com precisão decimal e recuperação aumentada (RAG) com citação rastreável até a fonte.

Experiência prática em orquestração multi-LLM (Gemini, Claude, OpenAI, Ollama) com atenção a custo por chamada, isolamento multi-tenant por Row Level Security e desenho de fluxos que preservam a decisão final com o humano nos pontos em que o erro é caro.

COMPETÊNCIAS TÉCNICAS

- **Linguagens:** Python 3.12, TypeScript, SQL, JavaScript
- **Backend:** FastAPI, Pydantic, SQLAlchemy, Alembic, Celery, Redis, pytest, WebSockets, APIs REST
- **Frontend:** React 18/19, Next.js 14/16, Vite, Tailwind CSS, React Flow, TanStack Query, Flutter
- **Dados:** PostgreSQL, Supabase, Firestore, Row Level Security, pgvector, pg_cron, Pandas, Polars, NumPy, BigQuery
- **IA & ML:** Gemini, Claude, OpenAI, Ollama, LangChain, RAG, embeddings, Vertex AI Vector Search, busca híbrida (RRF), protocolo A2A, XGBoost, scikit-learn, TensorFlow
- **Cloud & Infra:** Google Cloud Run, Cloud Tasks, Cloud Functions, Cloud Scheduler, Azure, Docker, Vercel, Git
- **Simulação & Estatística:** SimPy, NetworkX, Monte Carlo, ARIMA/SARIMA, statsmodels, SciPy, teste de estresse
- **Negócio:** Supply Chain, S&OP, planejamento de demanda, Strategic Sourcing, tributário brasileiro, Power BI, Tableau

PROJETOS DE DESTAQUE

Supply Chain, Simulação e Decisão

Supply Chain Pipeline Builder | Projeto autoral · Em evolução

Python · FastAPI · React · Pandas · statsmodels · SciPy

Construtor visual de pipelines de análise e previsão de demanda: cada card é uma operação, as colunas são detectadas do card anterior e cada etapa mostra prévia do resultado.

- 15 operações de ETL, análise de estoque (ABC/XYZ, estoque de segurança, ponto de reposição, lote econômico) e previsão por média móvel e ARIMA/SARIMA, com métricas MAE, RMSE e MAPE.
- Simulação de Monte Carlo sobre mais de 10.000 iterações para dimensionamento de estoque de segurança otimizado por custo.
- Exportação de qualquer pipeline como script Python ou notebook Jupyter executável, gerado inteiramente no navegador — decisão de produto para que o trabalho do analista não fique preso à ferramenta.
- Titularidade própria declarada em LICENSE. Atualmente em frente de integração com sistema corporativo de demanda planejada.

OmniTwin | Projeto autoral · Em desenvolvimento

Python 3.11 · SimPy · NetworkX · FastAPI · Pydantic · React Flow · MQTT · Celery · Redis

Gêmeo digital para resiliência de operações industriais, construído sobre a premissa de que operação não quebra na média — quebra na combinação de eventos.

- Motor de eventos discretos em SimPy com falha estocástica por MTBF/MTTR, matriz de setup por troca de SKU e validação de lista de materiais a cada processamento.
- Motor de cálculo desacoplado da interface de modelagem por esquemas JSON validados com Pydantic: trocar o front não toca o motor, e mudar o motor não invalida o modelo salvo.
- Teste de estresse variando parâmetro (ex.: atraso de fornecedor), com saída em série de nível de estoque, Gantt de falha e reparo por ativo, nó restritivo do fluxo e impacto financeiro da demanda não atendida.
- Telemetria ao vivo por MQTT com regra explícita de fallback ao valor estocástico do modelo quando o parâmetro está fora de faixa ou indisponível.

Sistemas Corporativos e Verticais de Negócio

Match Hub | Projeto autoral, posteriormente incorporado à operação · Em produção

Python 3.12 · FastAPI · Cloud Run · Firestore · Vertex AI Vector Search · Gemini Flash · React 19 · Cloud Tasks

Padronização e matching de insumos hospitalares com IA, resolvendo o problema de o mesmo item ser descrito de dezenas de formas diferentes entre hospitais, distribuidores e fabricantes.

- Normalização por LLM, embedding de 768 dimensões e busca vetorial, com segundo passe de re-ranqueamento; o que fica ambíguo vai para fila de curadoria humana em vez de virar match errado silencioso.
- Multi-tenant com isolamento por chave de API e catálogo canônico central com fluxo de proposta e aprovação; importação assíncrona via Cloud Tasks em lotes de 5.000 itens, sem travar a API.
- Promoção de itens entre bases reaproveita descrição, embedding e categoria já processados — arquitetura de cache desenhada em torno do custo de LLM, evitando cobrar duas vezes pelo mesmo processamento.
- Dois serviços Cloud Run a partir da mesma imagem, separados por variável de ambiente: um atende requisições, o outro consome a fila.

Tax-Hub | Sistema corporativo · MVP completo

TypeScript · React 19 · Vite · Tailwind CSS 4 · Supabase · PostgreSQL · decimal.js · Row Level Security

Simulação tributária para precificação interestadual, cobrindo a interação entre ICMS-ST, DIFAL, FCP, IPI e PIS/COFINS, em que a ordem de entrada no cálculo altera o resultado.

- Fórmulas fora do código: o analista fiscal cadastra a regra, valida contra golden cases e publica sem depender de fila de deploy — mudança legislativa deixou de ser demanda de engenharia.
- Linguagem de expressão própria, com tokenizer, parser e avaliador escritos à mão e sem uso de eval, para que fórmula cadastrada por usuário nunca seja executada às cegas.
- Motor de cálculo puro, sem I/O e sem dependência de framework, com precisão decimal; memória de cálculo passo a passo exportável para Excel com fórmulas vivas ou como documento de auditoria.
- Solver reverso por bisseção para os modos de preço-alvo e margem-alvo; resolvidor de regras fiscais por escopo, especificidade e janela de vigência.

LexMind | Desenvolvido sob contrato · Primeira vertical em desenvolvimento

Next.js 16 · Supabase · PostgreSQL 17 · pgvector · Claude Sonnet · Gemini 2.5 Pro · Vitest · Playwright

Copiloto jurídico para licitações e contratações públicas sob a Lei 14.133/2021, desenhado em torno da premissa de que assistente que inventa jurisprudência é pior do que assistente nenhum.

- Toda afirmação do copiloto carrega identificador de fonte resolvido em tempo real contra documento verificado: sem fonte, não há afirmação.
- Busca híbrida vetorial e full-text combinadas por RRF, porque termo jurídico exato e similaridade semântica falham em situações opostas.
- Agente analista entrega diagnóstico estruturado do edital — habilitação, prazos, cláusulas restritivas e contradições — antes da leitura humana.
- Isolamento entre escritórios testado como código, com suíte dedicada às políticas de Row Level Security.

Demais sistemas em operação ou sob contrato

- **Multi-Agent Assistant** — *Supply4Med · em operação*. Copiloto de operações em linguagem natural no Microsoft Teams, com leitura direta do Odoo ERP por API, agentes especialistas por domínio (CRM, projetos, suporte) e ciclo de planejar-e-agir para perguntas de múltiplos passos. Python, LLM, Azure, RAG.
- **Procurement Condominial** — *sob contrato · em uso*. Fluxo de compra da abertura da cotação à confirmação de pagamento, com Kanban por fase, mapa comparativo de fornecedores exportável em Excel e PDF, adjudicação item a item e alertas de SLA por pg_cron com deduplicação diária. Python 3.12, FastAPI, Supabase, React 18, TypeScript.
- **Sistema de Gestão Lótus Escoteiros** — *autoral · voluntário · em produção*. Gestão financeira e pedagógica para organização de 460 membros, com faturamento de regras compostas, workflow de reembolso com alçadas e fechamento mensal travado após aprovação do conselho fiscal. Operação a custo zero em camadas gratuitas, com keep-alive para impedir auto-pause do banco. Next.js 14, Supabase, Cloud Run.

P&D em Arquitetura Multiagente

Laboratório próprio para validar arquiteturas de IA em condições reais antes de propô-las em ambiente corporativo — com foco em custo de integração, autonomia entre componentes e limites de cada abordagem.

Ecossistema JARVIS | Projeto autoral · Fio completo em operação

Python 3.12 · FastAPI · Gemini · Pydantic · SQLAlchemy · Alembic · PostgreSQL · argon2 · pytest

- Quatro agentes em quatro repositórios e quatro processos, comunicando por protocolo A2A sobre HTTP: nenhum alcança o banco do outro. Orquestrador (JARVIS), memória de ativos (Alfred), finanças com painel web próprio (Lucius) e identidade/sessão extraída como pacote instalável (Portaria).
- Testes automatizados substituem as pontas de LLM por dublês determinísticos, por decisão explícita — teste não pode depender de chave de API nem de resposta que varia; a validação com modelo real roda separadamente, com agentes simultâneos no ar.

- Toda consulta expõe o drill-down das linhas que formaram cada número e declara o que ficou fora da soma e quanto isso representa; fato e previsão são mantidos em coleções distintas para impedir soma indevida por consumidores.
- Aprendizado transferível: agentes separados por protocolo custam mais para construir e devolvem autonomia real, incluindo a capacidade de um cair sem derrubar os demais.

Demais experimentos do laboratório

- **CyberSec Cockpit** — *autoral · em desenvolvimento*. Orquestração de testes de segurança sob regra authorization-first: o documento de autorização é auditado por IA e o escopo extraído dele governa o que pode ser executado. Encadeia análise estática, de dependências, dinâmica e de rede numa cadeia só, com revisão humana antes do relatório. Celery, Redis, WebSockets, roteamento entre provedores de LLM por custo e adequação.
- **Detective AI** — *autoral · protótipo funcional*. Avaliação de competências em engenharia de prompt e pensamento crítico por simulação investigativa, com suspeitos movidos por LLM que lembram, mentem e se contradizem. Arquitetura bring-your-own-key com opção de execução totalmente local via Ollama. Flutter, FastAPI, Docker.
- **Dedé** — *autoral · v1*. Estudo adaptativo para crianças com três agentes de papéis distintos e lógica de adaptação deliberadamente fora do LLM — média móvel exponencial ponderada pela dificuldade, em código testável — para comportamento previsível, auditável e barato. Troca de provedor por painel administrativo, sem redeploy. React, Firebase, Cloud Functions v2.

EXPERIÊNCIA PROFISSIONAL

Supply4Med | Head de Inteligência · Jul/2024 – Atual

- Liderei a criação da área de Inteligência, entregando o ecossistema de agentes de IA que integra Google Gemini, Microsoft Teams, Outlook, Odoo ERP e WebJobs, permitindo consulta a dados de projetos, CRM e tarefas em linguagem natural.
- Desenvolvi solução de padronização de descrições e consolidação de demanda de compras, elevando a qualidade da base de itens e viabilizando comparação de preço e análise de consumo confiáveis.
- Implementei plataforma de inteligência documental (RAG) para consulta centralizada de documentos internos, e agentes de coleta automatizada de informações de mercado para prospecção comercial.
- Construí sistema de governança de dados com conjunto de ferramentas por perfil e hierarquia de acesso, e agentes autônomos para geração e envio proativo de relatórios operacionais.
- Conduzi a definição e mensuração dos KPIs estratégicos da operação, alinhando métricas aos objetivos de negócio até o ponto de prontidão para desenvolvimento.
- **Head de Operações e Controle (função anterior)**: redução de 66% no tempo de execução de processos por automação, com dashboards de gestão de pedidos em Power BI.

Advison Consulting | Specialist Advisor · Jun/2023 – Mar/2024

- **Projeto LeadTime (Grupo Boticário)**: análise de dados operacionais extraídos do SAP e construção de relatórios e dashboards para redução de lead times ponta a ponta, com GCP/BigQuery, SQL Server, Dataprep, Power BI e Tableau.
- **Projeto ScoreCredit**: modelo preditivo de risco de crédito para distribuidor de medicamentos, com técnicas estatísticas e de machine learning (RFV) para otimizar limites e ampliar vendas com risco controlado.

EzTools | Gestor de Projetos · Mai/2022 – Jun/2023

- Arquiteto de soluções e gerente de múltiplos projetos de RPA e BPMS, com foco em desenho e otimização de processos complexos para automação. Clientes: Eurofarma, Atento, Sicoob.

What's on Tap? | Fundador · Out/2016 – Mai/2022

- Concepção e operação de startup no setor alimentício, com responsabilidade integral por plano de negócios, fluxo de caixa, orçamento e relação com fornecedores.

Rio 2016 — Comitê Organizador dos Jogos Olímpicos | Gerente de Compras · Ago/2015 – Set/2016

- Sourcing estratégico e aquisição de categorias de alto volume — utilidades, transporte de funcionários, atletas e espectadores, e equipamentos da vila dos atletas — com atuação no comitê de aprovação de compras.

EY | Gerente de Projetos · Out/2012 – Mai/2015

- Reestruturação da função de compras de empresa brasileira na Venezuela, com gestão de categorias e planejamento estratégico; projetos de sourcing estratégico para clientes de bens de consumo, químicos e agronegócio.
- Estruturação de PMO para pré-projetos de geração de demanda, compras e logística em grande atacadista, e formulação de estratégia de mercado para linha de refeições instantâneas.

Webb / BrainNet | Gerente de Projetos · Set/2007 – Out/2012

- Soluções logísticas para e-commerce e farmacêutico, incluindo modelo de remuneração diferenciado para provedores logísticos; sourcing estratégico em shoppings, equipamentos agrícolas, educação e varejo.
- Plano de negócios para entrada de fabricante alemão de equipamentos pesados no mercado brasileiro e estudo pioneiro sobre biomassa como fonte energética alternativa para a indústria de bebidas.

FORMAÇÃO E IDIOMAS

- **MBA em Gestão Estratégica e Econômica de Projetos** — FGV, 2013
- **Bacharelado em Administração de Empresas** — FGV/EAESP, 2003
- **Idiomas:** Português (nativo) · Inglês fluente (TOEIC 940) · Espanhol avançado

FORMAÇÃO COMPLEMENTAR

- Data Science & Supply Chain Analytics — conclusão prevista Jan/2026
- LLM Applications using LangChain — Udemy, 2024 · [certificado](#)
- Python — Hashtag Treinamentos, 2024 · [certificado](#)
- Data Science (estatística, NumPy, scikit-learn, TensorFlow 2.0) — 365 Careers, 2024 · [certificado](#)
- R Programming for Statistics and Data Science — 365 Careers, 2024 · [certificado](#)
- SQL — Hashtag Treinamentos, 2022 · [certificado](#)
- Gestão Ágil de Projetos com Scrum — Udemy, 2020 · [certificado](#)
- Sócio do Impact Hub São Paulo e Impact Hub Florianópolis; investidor do Impact Hub Belo Horizonte